

Debilidades de CUMUL como método de Website Fingerprinting ante páginas de similar tamaño

Autor: **Pablo Barriuso Cervera**

Director: **Daniel Morató Osés**

Codirector: **Yuri Murillo Mange**

Máster Universitario en Ciberseguridad


Junio de 2025

Índice

1. Contexto y objetivos
2. Escenario y metodología
 1. Generación de páginas web
 2. Modelo de amenaza
 3. Arquitectura de red
 4. Procesamiento de trazas
3. Marco experimental
4. Análisis de los resultados
5. Conclusiones y trabajo futuro

1 – Contexto y objetivos

1 – Contexto y objetivos



Porcentaje de páginas cargadas a través de HTTPS en Chrome por plataforma

Fuente: <https://transparencyreport.google.com/https/overview>

1 – Contexto y objetivos

HTTPS es empleado por millones de usuarios para asegurar la **privacidad y confidencialidad** de las comunicaciones

- HTTPS protege el **contenido** de los datos transmitidos
- No es suficiente para protegerse de ataques basados en el **análisis del tráfico**

Un ejemplo de este tipo de ataques es conocido como **Website Fingerprinting**

- Un adversario pretende averiguar qué página está visitando un usuario (víctima)
- Se plantea como un problema de **clasificación** con distintas fases

1 – Contexto y objetivos

Uno de los trabajos más relevantes en el campo de Website Fingerprinting es **Website Fingerprinting at Internet Scale**.

Panchenko, A., Lanze, F., Pennekamp, J., Engel, T., Zinnen, A., Henze, M., & Wehrle, K. (2016, February). Website Fingerprinting at Internet Scale. In NDSS (Vol. 1, p. 23477).

<https://nymity.ch/tor-dns/pdf/Panchenko2016a.pdf>

Número de citas: 430 (Scopus), 714 (Google Scholar)

Este trabajo combina la representación del tráfico mediante una secuencia acumulativa con metadatos de este. El método se conoce en la literatura como **CUMUL**.


1 – Contexto y objetivos

Fingerprint de CUMUL:

- Número de paquetes entrantes
- Número de paquetes salientes
- Volumen entrante
- Volumen saliente
- Secuencia acumulativa interpolada a 100 características

$$c_1 = p_1, a_1 = |p_1|$$


$$c_i = c_{i-1} + p_i, a_i = a_{i-1} + |p_i| \text{ para } i = 2, \dots, N$$



1 – Contexto y objetivos

El objetivo principal de este trabajo es estudiar las debilidades de **CUMUL**.

Para ello:



Definir un escenario desfavorable, a priori, para el método (páginas de igual tamaño)



Implementar y evaluar CUMUL en ese escenario




Analizar los resultados en busca de debilidades

2 – Escenario y metodología

2.1 – Generación de páginas web

Con el fin de tener **páginas similares** se propone un escenario donde las páginas tienen el **mismo tamaño total** pero distinto número de recursos.



2.1 – Generación de páginas web

Para crear el modelo de páginas se utilizan datos reales obtenidos de **HTTP Archive**

	Tamaño total en KB	Tamaño del html en KB
Percentil 10	607	5
Percentil 25	1372	14
Percentil 50	2678	34
Percentil 75	5375	75
Percentil 90	11171	151


Distribución del tamaño total de la página y del tamaño del HTML.

Fuente: <https://httparchive.org/reports/page-weight> 01-01-2025 desktop

Generamos **10 escenarios** con distintos tamaños de páginas.

Cada escenario tiene **30 páginas web** con un número de **recursos en el rango 5-64**

2.2 – Modelo de amenaza



Atacante **local** y **pasivo**:

- Visibilidad directa del tráfico
- No interfiere ni modifica el tráfico

2.3 – Arquitectura de red


Escenario construido con **Docker**

Cliente:

- Navega a sitios web (Selenium + Chrome)
- Captura las trazas de tráfico (Tcpdump)

Servidor:

- Genera las páginas web
- Sirve las páginas web (Nginx)



2.4 – Procesamiento de las trazas

- 10 tamaños de página distintos
- 30 clases por cada tamaño
- 31 instancias por cada clase
- 104 características
 - 4 metadatos
 - 100 características de la secuencia acumulativa

3 – Marco experimental

3 – Marco experimental

Evaluación de **CUMUL** (104 características + SVM con kernel RBF)


Evaluación de 3 configuraciones extra con RF:

1. Secuencia acumulativa + metadatos
2. Solo metadatos
3. Solo secuencia acumulativa

Análisis de importancia para las 3 configuraciones con RF

4 – Análisis de resultados

4 – Análisis de resultados



4 – Análisis de resultados

Solo secuencia acumulativa:

- Valores **tardíos** para páginas **pequeñas**
- Valores **tempranos** para páginas **grandes**
- La **precisión** para páginas grandes **decae rápidamente**

Label Size	Accuracy	Feature 1	Feature 2	Feature 3	Feature 4
511 828	0.935484	cumul_97	cumul_99	cumul_98	cumul_12
798 283	0.919355	cumul_97	cumul_99	cumul_98	cumul_96
800 378	0.953125	cumul_12	cumul_11	cumul_13	cumul_18
2 414 154	0.822222	cumul_3	cumul_2	cumul_4	cumul_7
2 771 049	0.794444	cumul_3	cumul_4	cumul_6	cumul_8
3 734 496	0.663102	cumul_2	cumul_3	cumul_1	cumul_5
3 871 694	0.604167	cumul_2	cumul_3	cumul_1	cumul_4
4 052 310	0.682796	cumul_2	cumul_1	cumul_3	cumul_5
7 638 443	0.625000	cumul_1	cumul_2	cumul_99	cumul_3
9 239 647	0.594444	cumul_1	cumul_99	cumul_2	cumul_98

4 – Análisis de resultados

Solo metadatos:

- Los **bytes y paquetes salientes** son más importantes en páginas **pequeñas**
- Los **bytes entrantes** son la característica más **importante en general**
- Precisión entre 75% - 80%

Label size	Accuracy	Feature 1	Feature 2	Feature 3	Feature 4
511 828	0.854839	outgoing_bytes	incoming_bytes	incoming_packets	outgoing_packets
798 283	0.865591	incoming_bytes	outgoing_bytes	incoming_packets	outgoing_packets
800 378	0.817708	outgoing_bytes	incoming_bytes	incoming_packets	outgoing_packets
2 414 154	0.777778	incoming_bytes	incoming_packets	outgoing_bytes	outgoing_packets
2 771 049	0.805556	incoming_bytes	incoming_packets	outgoing_packets	outgoing_bytes
3 734 496	0.748663	incoming_bytes	incoming_packets	outgoing_bytes	outgoing_packets
3 871 694	0.765625	incoming_bytes	incoming_packets	outgoing_bytes	outgoing_packets
4 052 310	0.763441	incoming_bytes	incoming_packets	outgoing_packets	outgoing_bytes
7 638 443	0.786458	incoming_bytes	incoming_packets	outgoing_packets	outgoing_bytes
9 239 647	0.816667	incoming_bytes	incoming_packets	outgoing_packets	outgoing_bytes

4 – Análisis de resultados


Metadatos + secuencia acumulativa:

- Los **bytes entrantes** son la característica más **importante en general**
- Valores **tardíos** para páginas **pequeñas**. Valores **tempranos** para páginas **grandes**
- Precisión entre 80% - 96%

Label Size	Accuracy	Feature 1	Feature 2	Feature 3	Feature 4
511 828	0.9355	outgoing_bytes	incoming_bytes	cumul_97	cumul_99
798 283	0.9409	incoming_bytes	outgoing_bytes	incoming_packets	cumul_97
800 378	0.9635	outgoing_bytes	incoming_bytes	cumul_12	incoming_packets
2 414 154	0.9222	incoming_bytes	incoming_packets	cumul_2	cumul_4
2 771 049	0.9167	incoming_bytes	incoming_packets	cumul_3	cumul_4
3 734 496	0.8770	incoming_bytes	incoming_packets	cumul_2	cumul_3
3 871 694	0.8333	incoming_bytes	incoming_packets	cumul_2	cumul_3
4 052 310	0.8602	incoming_bytes	incoming_packets	cumul_2	cumul_1
7 638 443	0.8021	incoming_bytes	incoming_packets	cumul_1	cumul_2
9 239 647	0.8389	incoming_bytes	incoming_packets	cumul_1	cumul_2

4.1 – Visualización de los datos

Volumen entrante vs volumen saliente por número de imágenes




Páginas de 511.828 bytes (pequeña)

- Ambas características son representativas

4.1 – Visualización de los datos

Volumen entrante vs volumen saliente por número de imágenes




Páginas de 2.414.154 bytes (mediana)

- Ambas características siguen siendo representativas
- Parece que los bytes salientes pierden algo de información

4.1 – Visualización de los datos

Volumen entrante vs volumen saliente por número de imágenes




Páginas de 4.052.310 bytes (mediana)

- Los bytes salientes no parecen aportar información

4.1 – Visualización de los datos

Paquetes entrantes vs paquetes saliente por número de imágenes




Páginas de 511.828 bytes (pequeña)

- Los paquetes entrantes parecen más relevantes que los salientes

4.1 – Visualización de los datos

Paquetes entrantes vs paquetes saliente por número de imágenes




Páginas de 2.414.154 bytes (mediana)

- ¿Menos paquetes salientes para páginas con más imágenes?
- Los paquetes entrantes siguen pareciendo relevantes

4.1 – Visualización de los datos

Paquetes entrantes vs paquetes saliente por número de imágenes



Páginas de 9.239.647 bytes (grande)

- ¿Menos paquetes salientes para páginas con más imágenes?
- Los paquetes entrantes siguen pareciendo relevantes

4.1 – Visualización de los datos

Los paquetes y bytes entrantes dependen en gran medida del contenido de la página

Los paquetes y bytes salientes están compuestos por:

- **Peticiones al servidor** (más recursos, más peticiones)
- **Confirmaciones de paquetes** (depende de la fragmentación en segmentos TCP y mecanismos como delayed ACKs)

5 – Conclusiones y trabajo futuro

5 – Conclusiones y trabajo futuro

Pese a fijar el tamaño total de las páginas, **CUMUL** sigue siendo **efectivo**.

Solo con **4 metadatos** tenemos un modelo estable de website fingerprinting (80% precisión).

No parece que la forma de la **secuencia acumulativa entera** sea **relevante**, solo los valores tempranos y tardíos.

No se han encontrado debilidades claras, pero el rendimiento cae para páginas grandes

5 – Conclusiones y trabajo futuro

Como trabajo futuro:

1. Limitar más el escenario: páginas que compartan el **mismo tamaño y mismo número de recursos**
2. Distintos **servidores**, distintas **características de red**
3. Evaluar el modelo tras aplicar mejoras como filtrar los paquetes **sin carga útil**
4. Repetir el experimento **empleando redes de anonimización** como Tor o Shadowsocks